

Manual Técnico AI Knowledge

Introducción

AI Knowledge es una plataforma diseñada para almacenar documentos y permitir que un asistente de inteligencia artificial responda preguntas utilizando únicamente la información cargada por el usuario.

La aplicación está desarrollada con Node.js y TypeScript. El backend utiliza Express como framework HTTP y Prisma como ORM para acceder a PostgreSQL.

Los documentos PDF se procesan automáticamente. Primero se extrae el texto, luego se divide en fragmentos (chunks), posteriormente se generan embeddings utilizando un modelo de inteligencia artificial y finalmente esos embeddings se almacenan en PostgreSQL mediante la extensión pgvector.

Arquitectura

El sistema está dividido en módulos independientes.

El módulo Auth administra el registro y autenticación de usuarios mediante JWT.

El módulo Workspace permite que cada usuario tenga múltiples espacios de trabajo completamente aislados.

Cada Workspace puede contener múltiples documentos y múltiples conversaciones.

El módulo Chat mantiene el historial de mensajes entre el usuario y la inteligencia artificial.

El módulo Documents procesa archivos PDF y extrae su contenido.

El módulo Embeddings genera representaciones vectoriales de cada fragmento del documento.

El módulo RAG recupera los fragmentos más relevantes antes de consultar al modelo de lenguaje.

Tecnologías

Frontend:

- React
- TypeScript
- TailwindCSS

Backend:

- Node.js
- Express
- Prisma
- PostgreSQL
- pgvector
- Multer
- pdf-parse

Inteligencia Artificial:

- Ollama
 - Qwen2.5
 - Embeddings Nomic Embed Text
-

Flujo de procesamiento

Cuando un usuario sube un documento ocurre el siguiente proceso.

El archivo PDF se almacena en disco.

Posteriormente se extrae todo el texto.

El texto se divide en fragmentos de aproximadamente mil caracteres.

Cada fragmento genera un embedding de 768 dimensiones.

Cada embedding se almacena junto al texto correspondiente.

Cuando un usuario realiza una pregunta se genera un embedding de la consulta.

Ese embedding se compara con todos los embeddings del workspace mediante similitud coseno.

Los cinco fragmentos más similares son enviados al modelo de lenguaje.

El modelo responde utilizando únicamente esos fragmentos.

Seguridad

Cada Workspace pertenece únicamente a un usuario.

Un usuario nunca puede acceder a documentos de otro Workspace.

Cada petición verifica el JWT.

Cada operación valida que el usuario sea propietario del recurso solicitado.

PostgreSQL

La aplicación utiliza PostgreSQL 17.

Se utiliza la extensión pgvector para realizar búsquedas vectoriales.

La base de datos almacena usuarios, workspaces, documentos, chats, mensajes y embeddings.

Todos los documentos eliminados también eliminan automáticamente sus chunks mediante ON DELETE CASCADE.

Docker

La aplicación utiliza Docker Compose.

Los servicios disponibles son:

- Backend
- PostgreSQL
- Ollama

Todos los servicios se comunican mediante una red interna de Docker.

Inteligencia Artificial

El modelo utilizado para responder preguntas es Qwen2.5.

Los embeddings se generan mediante nomic-embed-text.

La comunicación con Ollama se realiza mediante la API REST.